

Guia unificada: diccionario de datos y relaciones

Proposito del documento

Este documento describe los archivos CSV normalizados del dataset bancario usado para construir un modelo de Next Best Product.

Sirve como guia para que los estudiantes entiendan:

- Que representa cada archivo.
- Que contiene cada campo.
- Como se relacionan las tablas.
- Como se construye la variable objetivo.
- Como usar la estructura para entrenar o simular un modelo de recomendacion.

Vista general del modelo de datos

El dataset original viene como un archivo plano mensual. La normalizacion lo separa en tablas con responsabilidades distintas.

```
clientes.csv
|
| id_cliente
v
cliente_estado_mensual.csv ----- provincias.csv
|                                     ^
| cod_prov                         | cod_prov
|
| id_segmento
v
segmentos.csv

cliente_estado_mensual.csv
|
| id_cliente + fecha_corte + origen_datos
v
cliente_producto_mensual.csv ----- productos.csv
|                                     ^
| id_producto                       | id_producto
v
cliente_producto_alta.csv
|
```

Archivos incluidos

Archivo	Rol dentro del modelo de datos
clientes.csv	Tabla maestra de clientes.
provincias.csv	Catalogo de provincias.
segmentos.csv	Catalogo de segmentos comerciales.
productos.csv	Catalogo de productos financieros.
cliente_estado_mensual.csv	Estado mensual del cliente.
cliente_producto_mensual.csv	Estado mensual de cada producto por cliente.
cliente_producto_alta.csv	Eventos de adquisicion de productos nuevos.
dataset_next_best_product.csv	Dataset final para entrenar el modelo.

Relaciones entre archivos

Tabla origen	Campo origen	Tabla destino
clientes.csv	id_cliente	cliente_estado_mensual.csv
clientes.csv	id_cliente	cliente_producto_mensual.csv
clientes.csv	id_cliente	dataset_next_best_product.csv

Tabla origen	Campo origen	Tabla destino
provincias.csv	cod_prov	cliente_estado_mensual.csv
segmentos.csv	id_segmento	cliente_estado_mensual.csv
productos.csv	id_producto	cliente_producto_mensual.csv
productos.csv	id_producto	cliente_producto_alta.csv
productos.csv	id_producto	dataset_next_best_product.csv
cliente_estado_mensual.csv	id_cliente + fecha_corte + origen_datos	cliente_producto_mensual.csv

Tabla origen	Campo origen	Tabla destino
cliente_producto_mensual.csv	id_cliente + fecha_corte + origen_datos + id_producto	cliente_producto_alta.csv

Claves sugeridas

Archivo	Clave sugerida
clientes.csv	id_cliente
provincias.csv	cod_prov
segmentos.csv	id_segmento
productos.csv	id_producto
cliente_estado_mensual.csv	id_cliente + fecha_corte + origen_datos
cliente_producto_mensual.csv	id_cliente + fecha_corte + origen_datos + id_producto
cliente_producto_alta.csv	id_cliente + fecha_corte + origen_datos + id_producto
dataset_next_best_product.csv	id_cliente + fecha_corte + origen_datos + id_producto_candidato

1. clientes.csv

Proposito

Tabla maestra de clientes. Contiene atributos relativamente estables y permite identificar si el cliente aparece en entrenamiento, en test o en ambos.

Granularidad

Una fila por cliente.

Campos

Campo	Tipo sugerido	Descripcion	Uso recomendado
id_cliente	Entero	Identificador unico del cliente. Proviene de ncodpers .	Clave para unir con tablas mensuales y de productos.
ind_empleado	Texto/categorico	Indicador de si el cliente es empleado del banco.	Variable explicativa.
pais_residencia	Texto/categorico	Pais de residencia del cliente.	Variable explicativa o filtro.
sexo	Texto/categorico	Sexo registrado del cliente.	Variable explicativa.
fecha_alta	Fecha	Fecha de ingreso del cliente al banco.	Puede usarse para calcular antiguedad.
conyuemp	Texto/categorico	Indicador de si el conyuge del cliente es empleado del banco.	Variable opcional.
canal_entrada	Texto/categorico	Canal por el que ingreso el cliente al banco.	Variable explicativa.
indfall	Texto/categorico	Indicador de cliente fallecido.	Puede usarse como filtro.
aparece_en_train	Binario	Vale 1 si el cliente aparece en train_ver2.csv .	Control de datos.
aparece_en_test	Binario	Vale 1 si el cliente aparece en test_ver2.csv .	Control de datos.

Relaciones

- Se une con `cliente_estado_mensual.csv` usando `id_cliente` .
- Se une con `cliente_producto_mensual.csv` usando `id_cliente` .
- Se une con `dataset_next_best_product.csv` usando `id_cliente` .

2. provincias.csv

Proposito

Catalogo de provincias. Evita repetir el nombre de la provincia en cada registro mensual.

Granularidad

Una fila por provincia.

Campos

Campo	Tipo sugerido	Descripcion	Uso recomendado
cod_prov	Entero/texto	Codigo de provincia del cliente.	Clave para unir con cliente_estado_mensual.csv .
nombre_provincia	Texto/categorico	Nombre de la provincia.	Variable geografica interpretable.

Relaciones

- Se une con cliente_estado_mensual.csv usando cod_prov .

3. segmentos.csv

Proposito

Catalogo de segmentos comerciales.

Granularidad

Una fila por segmento.

Campos

Campo	Tipo sugerido	Descripcion	Uso recomendado
id_segmento	Entero	Identificador del segmento.	Clave para unir con cliente_estado_mensual.csv .
descripcion_segmento	Texto/categorico	Nombre o descripcion del segmento comercial.	Variable explicativa.

Relaciones

- Se une con cliente_estado_mensual.csv usando id_segmento .

4. productos.csv

Proposito

Catalogo de productos financieros. Reemplaza las columnas originales de productos por una dimension normalizada.

Granularidad

Una fila por producto financiero.

Campos

Campo	Tipo sugerido	Descripcion	Uso recomendado
id_producto	Entero	Identificador unico del producto.	Clave para unir con tablas de productos y altas.
campo_original	Texto	Nombre original de la columna en el dataset Santander.	Trazabilidad hacia el archivo original.
nombre_producto	Texto/categorico	Nombre entendible del producto financiero.	Interpretacion de resultados.
categoria_producto	Texto/categorico	Categoria general del producto.	Feature del producto candidato.

Relaciones

- Se une con `cliente_producto_mensual.csv` usando `id_producto`.
- Se une con `cliente_producto_alta.csv` usando `id_producto`.
- Se une con `dataset_next_best_product.csv` usando `id_producto = id_producto_candidato`.

5. cliente_estado_mensual.csv

Proposito

Tabla de estado mensual del cliente. Contiene variables que pueden cambiar de un mes a otro.

Granularidad

Una fila por cliente, fecha de corte y origen de datos.

Campos

Campo	Tipo sugerido	Descripcion	Uso recomendado
id_cliente	Entero	Identificador unico del cliente.	Clave de union.
fecha_corte	Fecha	Fecha mensual de observacion. Proviene de <code>fecha_dato</code> .	Momento desde el que se predice.
origen_datos	Texto/categorico	Indica si la fila viene de <code>train</code> o de <code>test</code> .	Control de separacion de datos.
es_test	Binario	Vale 1 si la fila viene de test; 0 si viene de train.	Identificacion rapida de test.
age	Entero	Edad del cliente en el mes observado.	Variable numerica.
antiguedad	Entero	Antiguedad del cliente en el banco.	Variable numerica.
ind_nuevo	Binario/categorico	Indicador de cliente nuevo.	Variable explicativa.
indrel	Categorico	Tipo de relacion del cliente con el banco.	Variable explicativa.
indrel_1mes	Categorico	Relacion del cliente al inicio del mes.	Variable explicativa.
tiprel_1mes	Categorico	Tipo de relacion comercial del cliente en el mes.	Variable explicativa.
indresi	Categorico	Indicador de residencia.	Variable o filtro.
indext	Categorico	Indicador de cliente extranjero.	Variable explicativa.
ind_actividad_cliente	Binario/categorico	Indicador de actividad del cliente.	Variable importante para modelado.

Campo	Tipo sugerido	Descripcion	Uso recomendado
renta	Numerico	Renta o ingreso estimado.	Variable numerica; puede requerir imputacion.
cod_prov	Entero/texto	Codigo de provincia.	Clave para unir con <code>provincias.csv</code> .
id_segmento	Entero	Identificador de segmento comercial.	Clave para unir con <code>segmentos.csv</code> .

Relaciones

- Se une con `clientes.csv` usando `id_cliente`.
- Se une con `provincias.csv` usando `cod_prov`.
- Se une con `segmentos.csv` usando `id_segmento`.
- Se une con `cliente_producto_mensual.csv` usando `id_cliente` + `fecha_corte` + `origen_datos`.

6. cliente_producto_mensual.csv

Proposito

Tabla de relacion cliente-producto-mes. Indica si un cliente tenia activo o no un producto financiero en una fecha de corte.

Granularidad

Una fila por cliente, fecha de corte, origen de datos y producto.

Campos

Campo	Tipo sugerido	Descripcion	Uso recomendado
id_cliente	Entero	Identificador unico del cliente.	Clave de union.
fecha_corte	Fecha	Fecha mensual de observacion.	Define el estado del producto en ese mes.
origen_datos	Texto/categorico	Indica si la fila viene de <code>train</code> o de <code>test</code> .	Control de separacion de datos.

Campo	Tipo sugerido	Descripcion	Uso recomendado
id_producto	Entero	Identificador del producto financiero.	Clave para unir con productos.csv .
estado_producto	Binario	Vale 1 si el cliente tiene activo el producto; 0 si no.	Feature principal del historial de productos.

Relaciones

- Se une con clientes.csv usando id_cliente .
- Se une con productos.csv usando id_producto .
- Se une con cliente_estado_mensual.csv usando id_cliente + fecha_corte + origen_datos .

Nota

Esta tabla solo se genera para fuentes que tienen columnas de productos. El archivo test_ver2.csv original no trae esas columnas.

7. cliente_producto_alta.csv

Proposito

Tabla de eventos de alta de productos. Identifica cuando un cliente adquiere un producto nuevo.

Granularidad

Una fila por cliente, fecha de corte, origen de datos y producto adquirido.

Regla de negocio

Un alta de producto ocurre cuando:

```
estado_producto_mes_anterior = 0
estado_producto_mes_actual = 1
```

Entonces:

```
flag_alta_producto = 1
```

Campos

Campo	Tipo sugerido	Descripcion	Uso recomendado
id_cliente	Entero	Identificador unico del cliente.	Clave de union.
fecha_corte	Fecha	Mes en el que se detecta la adquisicion del producto.	Momento del evento objetivo.
origen_datos	Texto/categorico	Indica si la fila viene de train o de test .	Control de separacion de datos.
id_producto	Entero	Producto adquirido por el cliente.	Clave para unir con productos.csv .
flag_alta_producto	Binario	Vale 1 cuando el producto aparece como nuevo en ese mes.	Indicador del evento positivo.

Relaciones

- Se deriva de `cliente_producto_mensual.csv` .
- Se une con `productos.csv` usando `id_producto` .
- Se puede unir con `cliente_estado_mensual.csv` usando `id_cliente + fecha_corte + origen_datos` .

8. dataset_next_best_product.csv

Proposito

Dataset final para entrenar o simular un modelo de Next Best Product. Cada fila evalua un producto candidato para un cliente en una fecha de observacion.

Granularidad

Una fila por cliente, fecha de corte, origen de datos y producto candidato.

Variable objetivo

y

y = 1 si el cliente adquiere el producto candidato en el siguiente periodo.
y = 0 si el cliente no adquiere el producto candidato en el siguiente

periodo.

Campos

Campo	Tipo sugerido	Descripcion	Uso recomendado
id_cliente	Entero	Identificador unico del cliente.	Clave de union o identificador para scoring.
fecha_corte	Fecha	Mes de observacion desde el que se predice.	Referencia temporal.
origen_datos	Texto/categorico	Indica si la fila viene de <code>train</code> o de <code>test</code> .	Control de separacion.
id_producto_candidato	Entero	Producto que se evalua como posible recomendacion.	Feature o clave hacia <code>productos.csv</code> .
edad	Entero	Edad del cliente en la fecha de observacion.	Variable numerica.
antiguedad	Entero	Antiguedad del cliente en el banco.	Variable numerica.
renta	Numerico	Renta o ingreso estimado.	Variable numerica; puede requerir imputacion.
segmento	Texto/categorico	Segmento comercial del cliente.	Variable categorica.
ind_actividad_cliente	Binario/categorico	Indicador de cliente activo.	Variable explicativa.
tiene_producto_actualmente	Binario	Indica si el cliente ya tenia el producto candidato.	Feature o filtro para productos ya contratados.
cantidad_productos_actuales	Entero	Cantidad total de productos activos	Variable de intensidad de

Campo	Tipo sugerido	Descripcion	Uso recomendado
		del cliente.	relacion.
tiene_cuenta	Binario	Indica si el cliente tenia algun producto de tipo cuenta.	Feature agregada por categoria.
tiene_credito	Binario	Indica si el cliente tenia algun producto de tipo credito.	Feature agregada por categoria.
tiene_tarjeta	Binario	Indica si el cliente tenia algun producto de tipo tarjeta.	Feature agregada por categoria.
tiene_inversion	Binario	Indica si el cliente tenia algun producto de inversion.	Feature agregada por categoria.
categoria_producto_candidato	Texto/categorico	Categoria del producto candidato.	Feature del producto a recomendar.
y	Binario	Variable objetivo.	Target para entrenamiento supervisado.

Relaciones

- Se construye a partir de `cliente_estado_mensual.csv` , `cliente_producto_mensual.csv` , `cliente_producto_alta.csv` y `productos.csv` .
- Se une con `productos.csv` usando `id_producto_candidato = id_producto` .
- Se une con `clientes.csv` usando `id_cliente` .

Flujo recomendado para estudiantes

1. Entender entidades

Identificar que el archivo plano original mezcla:

- Clientes.

- Meses.
- Provincias.
- Segmentos.
- Productos.
- Eventos de adquisicion.

2. Usar las tablas normalizadas

Las tablas normalizadas separan responsabilidades:

- Dimensiones: `clientes.csv` , `provincias.csv` , `segmentos.csv` , `productos.csv` .
- Hechos mensuales: `cliente_estado_mensual.csv` , `cliente_producto_mensual.csv` .
- Eventos: `cliente_producto_alta.csv` .
- Modelado: `dataset_next_best_product.csv` .

3. Construir features

Ejemplos de variables:

- Edad.
- Antigüedad.
- Renta.
- Segmento.
- Provincia.
- Actividad del cliente.
- Cantidad de productos actuales.
- Si tiene cuenta.
- Si tiene credito.
- Si tiene inversion.
- Categoría del producto candidato.

4. Construir la variable objetivo

La variable objetivo se basa en la adquisicion futura:

```
Producto no estaba activo en el mes t
Producto aparece activo en el mes t+1
Entonces  $y = 1$ 
```

5. Entrenar el modelo

El modelo aprende con filas historicas de `train` .

Formato conceptual:

```
cliente + mes + producto candidato -> probabilidad de adquirir producto
```

6. Generar recomendaciones

Para cada cliente:

1. Evaluar productos candidatos.
2. Excluir productos que ya tiene, si aplica.
3. Calcular probabilidad de adquisicion.
4. Ordenar productos por probabilidad.
5. Recomendar el producto con mayor probabilidad o el top N.

Precauciones importantes

- No usar informacion futura como variable predictora.
- Separar correctamente `train` y `test` .
- No usar `y` como feature.
- Revisar valores faltantes en `renta` , `segmento` y campos categoricos.
- Codificar variables categoricas antes de entrenar modelos tradicionales.
- Si `cliente_producto_alta.csv` esta vacio en una muestra pequena, puede deberse a que no hay meses consecutivos suficientes por cliente.